

美国 SELF DRIVE Act of 2026 法案解读

目录

1 法案概述

- 1.1 法案的核心意义
- 1.2 法案前状态
- 1.3 法案的突破点
- 1.4 对行业的正面影响
- 1.5 负面影响

2 法案与 WP29 结构对比

- 2.1 监管“入口机制”不同
- 2.2. “合规结构形态”不同
- 2.3. “自动驾驶范围”聚焦不同
- 2.4. 数据与透明度工具不同

3 把 Safety Case 条目对齐到 WP.29

- 3.1 Safety Case (§ 30130(b)(3)) 条目 → WP.29 证据目录映射
- 3.2 核心能力 (§ 30130(b)(4)) → WP.29 (R155/R156/R157/ADS 指南) 映射

4 对中国自动驾驶监管的潜在影响

- 4.1 “安全案例”可能成为中国自动驾驶规模化准入的关键制度工具
- 4.2. 中国可能不会照搬“联邦优先权”，但会更重视“全国口径统一”
- 4.3 网络安全与软件更新：中欧趋同更强，美国法案提供“安全案例化”表达
- 4.4. 对中国产业的“正负效应”预判
- 4.5 结论

5 法案与安全大脑的关系

- 5.1 法案的监管对象
- 5.2 “安全大脑”在这个结构里的位置

5.3 Safety Case 与安全大脑的深层关系

5.4 如果没有安全大脑，怎样开展 Safety Case 验证？

5.5 法规条款的可落地“安全大脑系统架构”

6 安全大脑的机遇

附录— Safety Case 简介

1 法案总览

1.1 法案要点

1.1.1 从“豁免制”走向“专用标准制”

历史上美国自动驾驶推进的最大制度障碍是：FMVSS 是为“人类驾驶员”设计的，自动驾驶只能通过“豁免”路径进入市场。本法案删除原草案中的 90,000 辆豁免额度方案，转而建立

- ADS 专用安全标准（30130）
- 安全案例（Safety Case）强制机制
- 专用车辆合法路径（无方向盘/踏板）

这是一个从“例外”到“正当合规路径”的制度逻辑根本改变，意味着自动驾驶不再被当作“例外技术”，而是进入正式监管体系。

1.1.2 建立“安全案例”（Safety Case）制度化框架

本法案要求制造商必须为每一类 ADS 编制 Safety Case，并能证明“不会带来不合理风险”，本质上是将英国的 Safety Case 思维和航空安全体系逻辑，正式移植到美国机动车监管体系。这是一种责任前置型监管模型，而不是事后处罚模型。

1.1.3 明确 L3/L4/L5 的法律地位

法案正式采纳 SAE J3016 定义，并将 DDT、ODD、MRC、VRU（弱势道路使用者）、Fallback 机制写入美国法典层级。这解决了一个“自动驾驶在法律体系中到底是什么？”的关键问题：以前自动驾驶是监管灰区，现在有了法定身份。

1.1.4 确立联邦优先权

法案明确规定“州政府不得阻止合规 ADS 的销售或部署”。这一点极其重要，是因为过去十年，美国自动驾驶面临加州模式、亚利桑那模式和各州差异监管的制约，法案为全国统一市场打开通道。

1.1.5 建立国家 ADS 安全数据库

法案强制事故 30 日内报告、季度里程报告，以及建立国家级数据库，为未来数据驱动监管、风险建模提供基础。

1.2 法案前状态

- 美国监管碎片化
- ADS 只能通过豁免推进，规模受限
- 无方向盘车辆合法性不确定
- 安全案例制度缺失 → 安全评估缺乏标准化
- 州际部署成本极高
- 资本信心反复波动

长期负面效应：中国和欧盟在制度确定性领先与美国。

1.3 法案的突破点

1.3.1 不再依赖 FMVSS 豁免额度

实际上承认了“传统人类驾驶标准不再适用未来系统”，这是监管哲学上的一次跃迁。

1.3.2 无人工控制装置合法化

明确允许无方向盘、无踏板、无驾驶位，为 Robotaxi 真正量产铺平道路。

1.3.3 商业测试运营合法化

测试期间可载客、可载货、可收费，为 Waymo、Cruise、Zoox 提供合法商业化过渡路径。

1.3.4 网络安全被写入核心能力

将网络攻击防护纳入 ADS 核心能力，是一个重要升级。承认自动驾驶本质是“软件系统 + 网络系统”。

1.4 对行业的正面影响

1.4.1 资本

制度确定性 = 资本回流。不确定性下降后，IPO 窗口可能重新打开，车企投资会更激进。

1.4.2 技术

“安全案例”要求推动：系统工程化、危险分析体系成熟、功能安全 + 预期功能安全融合。

1.4.3 商业模式

合法规模化成为可能导致 Robotaxi fleet 扩张、无驾驶舱设计优化、成本结构重构。

1.4.4 供应链

传感器、高算力芯片、冗余制动转向系统、网络安全供应商都会受益。

1.4.5 主要受益者

直接受益者：Waymo、Zoox、Cruise、Aurora、Motional、自动驾驶初创企业。

间接受益者：英伟达等计算平台供应商、高精地图公司、车载通信与 V2X 公司、保险科技公司。

长期受益者：出行弱势群体、老龄人口、物流行业。

1.5 负面影响

1.5.1. 安全案例 (Safety Case) “合规化风险”

Safety Case 如果变成文件游戏，而不是实质安全提升，可能导致监管形式化、技术过度包装。

1.5.2 联邦优先权压缩了州级实验空间

州监管创新能力可能被削弱。

1.5.3 竞争加剧 → 中小企业被淘汰

安全案例（见附录）编制成本极高，大企业更容易承担。

1.5.4 事故风险社会容忍度问题

一旦出现严重 L4 事故、VRU 群体死亡事件，政治反弹风险仍然存在。

1.6 总结

这是自 2017 年以来美国自动驾驶立法的最大制度跃迁，不能看作是简单的放松监管，而是从“人类驾驶监管框架”转向“系统责任监管框架”。

核心变化在于：

- 承认 ADS 是“驾驶主体”
- 将责任转向系统安全证明
- 将监管前移

从制度哲学看，这个法案完成了一件重要的事：将“判断责任”从人类驾驶员，部分转移到制造商的系统安全论证上，这是一种责任结构的重构。这不仅影响自动驾驶，也可能成为未来 AI 系统监管的模板。

2 法案与 WP29 结构对比

2.1 监管“入口机制”不同：型式认证 vs 自我符合 + 事后执法

欧盟/UNECE (WP.29) 是典型的“型式认证” (Type Approval / WVTa) 路径：车辆/系统必须先获得主管机关的批准，才能进入市场，更像“拿证上路”。欧盟整体属于“先审后放”。

美国（本法案）延续美国传统：制造商自我证明符合性，NHTSA 以标准、抽查、召回、罚则等“执法”工具做后置监管，更像“先上路但要能随时拿出证明，并承担责任。法案虽然引入 Safety Case，但仍是“制造商必须编制并能提交”的合规义务，整体仍更接近“自证 + 可问责”。

2.2. “合规结构形态”不同：细颗粒规则包 vs 体系化安全论证

WP.29 的典型交付物是 UN Regulations（例如网络安全、软件更新，以及自动驾驶相关条目）。其监管结构更偏向明确的规则条款清单、过程性合规要求、可审核的体系文件，和型式认证前置条件。例如，网络安全管理体系（CSMS）与软件更新管理体系（SUMS）已成为型式认证的前置要求。企业必须证明其管理体系、流程结构、控制措施满足规定格式与审核标准。其逻辑可以概括为：“条款满足 + 过程可验证 + 结构可审查”，换言之，WP.29 更强调可审查的合规形态，而不是企业自行构建风险接受模型。

相比之下，SELF DRIVE Act 2026 的核心机制是将 Safety Case 写入法典结构。企业必须通过“主张—论据—证据（Claim – Argument – Evidence）”的方式，证明其自动驾驶系统：

- 不存在“不合理风险（Unreasonable Risk）”
- 能在其 ODD 内安全运行
- 能处理 DDT 失败
- 能进入最小风险状态（MRC）

- 能识别并响应 VRU、应急车辆、校车等关键对象
- 具备网络安全与远程操作策略

这里的关注点不是条款清单，而是风险论证是否充分、证据是否充足、推理结构是否自洽。

2.3. “自动驾驶范围”聚焦不同：欧盟更谨慎分步；2026 法案直接为 L4/L5 开路

WP.29 的现行路径总体呈现“功能先行、场景渐进”的特征，其监管逻辑并非一次性为完全无人驾驶开放制度入口，而是围绕具体自动化功能形态逐步建立法规框架。典型做法是对某些明确边界的功能先行规范，在限定运行条件（如特定道路类型、速度范围、环境条件）下推进合规机制。同时，在 GRVA（自动驾驶与网联车辆工作组）等框架内持续推进 ADS 的更广义技术指南、建议性文件以及全球技术法规（GTR）相关工作，逐步外扩监管边界。整体路径体现为：从可控、有限 ODD 的功能出发，逐层扩大自动化能力的监管覆盖范围。这种方式强调风险可控、逐级验证、渐进式制度适配。

本法案：直接定义 ADS-DEDICATED VEHICLE（L4/L5 专用车辆），并提供“无方向盘/踏板”等人工控制装置豁免的法定合规路径；同时对 L3 规定“后备就绪用户”与接管要求。

所以，欧盟路径更像“从 L2/L3 可控形态逐步外扩”；美国法案则是“把 L4/L5 专用车一次性放入联邦框架”。

2.4. 数据与透明度工具不同：欧盟更偏型式合规资料；法案强调“国家级运行数据+事故库”

本法案强制建立国家 ADS 安全数据库，作为联邦层面的统一信息平台。其核心机制包括：

- 明确的事定义与分类标准
- 强制事故上报时限
- 季度运行里程报告要求

- 与州政府的数据共享机制
- 在法案生效后替代或废止 NHTSA 2021-01 通用命令

这一结构意味着自动驾驶运行数据不再只是企业内部或执法调查资料，而是成为一个制度化、持续更新、全国统一口径的联邦数据库。监管逻辑从“事后个案调查”转向“持续运行透明化 + 宏观风险监测”。因此，数据本身成为监管工具的一部分，而不仅仅是合规证明材料。

相比之下，WP.29 体系更常见的做法是，将数据、网络安全、软件更新等要求纳入型式认证文件，通过 CSMS（网络安全管理体系）、SUMS（软件更新管理体系）进行持续合规审查，要求企业具备数据记录与事件响应机制，但其结构重点在于：体系是否建立、流程是否存在、管理机制是否有效，而不是建立一个统一的跨企业、跨成员国的“中央事故与里程数据库”。

结构差异总结：WP.29 路径更强调“企业内部管理体系 + 型式认证文件化审查”；2026 法案更强调：“联邦统一运行数据平台 + 标准化事故与里程口径”。两者的根本差异在于：是把数据作为“企业合规的一部分”，还是把数据作为“国家级持续风险监测工具”？

在这次对照范围内，本法案所设立的“中央数据库机制”是其制度结构上的显著特征。

2.5. 法律层级治理目标不同：美国强调“联邦优先权统一市场”；欧盟靠“欧盟法”

《2026 年自动驾驶安全法案》明确设立联邦优先权（Federal Preemption）机制，其核心含义是：凡满足联邦 Safety Case 要求与相关 ADS 专用标准的自动驾驶系统或车辆，州政府不得以州法律形式阻止其销售或部署，也不得另行设立与联邦标准不一致的技术合规要求或碰撞报告义务。同时，州仍保留交通执法、车辆登记、保险制度、消费者保护等传统权限。

这种结构体现的是：在技术合规与市场准入层面实现全国统一，在道路管理与执法层面保留地方自治空间。其目标是避免出现“州级监管碎片化”，从而保障自动驾驶产业在全国范围内的规模化部署能力。

欧盟路径则依托欧盟法域统一与型式认证体系实现市场整合。通过欧盟法规与 UNECE 型式认证框架，形成统一的准入标准。一旦获得型式认证，车辆即可在成员国之间流通销售。成员国在道路运行规则、执法细节、责任认定等方面仍可能存在差异，但由于“准入证照”本身由欧盟统一框架确立，市场入口已被制度性统一。

结构差异总结：美国通过“联邦优先权”避免州际监管分裂；欧盟通过“统一型式认证”避免成员国准入标准分裂。两者的制度目标一致：统一市场，但实现路径不同。美国通过联邦立法压平州级技术标准；欧盟通过统一认证制度压平成员国准入门槛。

3 把 Safety Case 条目对齐到 WP.29

下面把 SELF DRIVE Act 2026 的 Safety Case (§ 30130(b)(3) A – G) + 核心能力 (§ 30130(b)(4) A – H)，对齐到 WP.29/GRVA 体系下常用的证据目录（重点覆盖 UN R155 网络安全/CSMS、UN R156 软件更新/SUMS、UN R157 (ALKS) 里对 ODD/MRM/接管等安全概念与要求、以及 GRVA 的 ADS 安全指南/建议）。

3.1 Safety Case (§ 30130(b)(3)) 条目 → WP.29 证据目录映射

SELF DRIVE Safety Case 条目	应准备的“证据包”目录 (工程输出)	WP.29 对应“证据目录/合规材料”锚点	备注：用于安全大脑 KG/规则工程的可结构化字段示例
(A) 硬件/软件组件说明：制动、转向、算力、冗余、传感器套件、平台集成	System Architecture Pack：EEA/功能分配、冗余链路、传感器规格、执行器安全机制、接口矩阵、FMEA/FMEDA 概览	WP.29 ADS/GRVA 安全指南强调体系化安全评估与测试方法（非单一款），R157 也对系统行为与安全概念（如 MRM）	Subsystem, Interface, RedundancyType, SafetyMechanism, FailureMode, Assumption

		提出要求口径，可作为“系统能力证据”挂接点。	
(B) ODD 完整说明 + DDT 执行方式	ODD Definition Pack: ODD 参数空间、边界条件、场景本体/场景库、能力覆盖矩阵、运行限制与退出策略	R157 明确使用 ODD 相关概念、并对系统在特定条件下行为（含最小风险动作/机动）形成法规语言。	ODD.Dimension（天气/道路/速度/交通密度/时间段等）， ODD.BoundaryDetection, ExitCondition, ScenarioID
(C) 工程方法：危险分析方法等	Safety Engineering Methods Pack: HARA/STPA/FTA、场景危害分析、SOTIF 论证结构、验证策略（仿真/封闭场/道路）	GRVA ADS 安全指南专门面向“安全要求、评估与测试方法”的证据组织方式（更接近 Safety Case 思维）。	Hazard, CausalFactor, SafetyGoal, AcceptanceCriteria, EvidenceLink
(D) 安全性能分析：正常/避撞核心能力 + 验收标准	Performance Evidence Pack: KPI 定义、ODD 内覆盖率、长尾场景策略、避撞性能、鲁棒性/不确定性评估、验收门槛	R157 对系统性能与安全相关行为有更“可型式审查”的要求表达方式（尤其涉及系统在失效/退出时的安全动作）。	KPI, Metric, Threshold, Coverage, EdgeCase, ValidationResult
(E) 预判与应对潜在碰撞机制	Collision Anticipation & Mitigation Pack: 风险预测模型、TTC/风险指标、行为规划安全护栏、紧急策略、VRU 保护策略	GRVA ADS 安全指南强调风险评估与测试；R157 也间接要求在系统接管失败等情况下采取最小风险动作。	RiskIndicator, Trigger, MitigationAction, VRUType, DecisionRule
(F) 集成式危险警示系统：进入/执行 MRC 时的视觉/数字警示、V2X 提示等	External Communication Pack: HMI/外部灯光策略、eHMI、V2X 消息集、触发条件、合规与可理解性验证	R157 对“最小风险机动/状态”的术语与要求口径清晰；这类外部警示在 WP.29 体系里通常作为“系统安全行为+对其他道路使用者风险控制”的证据来审查。	MRC.State, WarningMode, V2X.MessageType, ActivationLogic, ComprehensionTest
(G) 说明如何满足核心能力 (§ 30130(b)(4))	Core Capability Compliance Matrix: 逐条能力 → 设计实现 → 测试证据 → 运行监控证据	WP.29 在 R155/R156 更强“过程与体系证据”；在 R157/ADS 指南更强“系统行为与验证证据”。	RequirementID, DesignControl, VerificationMethod,

			EvidenceArtifact, ResidualRisk
--	--	--	-----------------------------------

3.2 核心能力（§ 30130(b)(4)）→ WP.29（R155/R156/R157/ADS 指南）映射

SELF DRIVE 核心能力	应准备的证据 (最小集合)	WP.29 对应锚点	实现途径
(A) ODD 内执行 DDT + 识别 ODD 边界	ODD 边界检测证明、退出策略、ODD 覆盖验证、异常检测	R157 对系统在限定条件下的行为/退出与“最小风险机动”语言体系可对齐。	用“ODD 参数→条件判定→状态机”建成可机读规则，便于一致性审查
(B) 检测并妥善应对 ODD 内 VRU	VRU 检测性能、误检漏检分析、策略证明、场景覆盖	ADS 安全指南强调评估与测试方法；R157/相关法规语言也支持“道路使用者风险”论证。	VRU 类别做本体化：行人/骑行者/轮椅等，直接对应证据统计维度
(C) L3 状态传递 + 介入请求 + 充分接管时间、接管前持续控制	HMI 规范、接管时序、最小接管时间、驾驶员监控策略、接管失败处理	R157 中与“接管/过渡需求（transition demand）/MRM”等概念紧密相关。	把“接管请求→人机状态→计时→失败分支”建成可验证状态机
(D) L4/L5 必要时可进入 MRC	MRC 触发条件、执行轨迹、风险证明、边界场景验证	R157 对 MRM/MRC 相关定义与要求非常直接，是最佳对齐锚点。	可以把 MRC 当作“安全不变量”：无论场景如何，都要收敛到可证明安全的终态集合
(E) 当 ODD 条件不满足时妥善应对：L4/5 进 MRC；L3 请求接管	ODD 违约检测、降级策略、MRC/接管联动证据	R157（退出/过渡/MRM）+ ADS 安全指南（验证方法）	在证据包里把“ODD 违约类型”做枚举：天气/道路/定位/传感器退化等
(F) 识别并应对应急车辆/应急人员/校车等事件	特殊目标识别性能、策略与法规遵循说明、场景验证	ADS 安全指南（评估/测试方法）更好挂接；各地区细则不同，需把“识别→策略→法域参数”分离。	最适合用安全大脑的“规则插件化”：各法域差异用参数/规则模块切换
(G) 遵守适用州/地方交通法规及与 DDT 相关法律	法规映射矩阵、行为合规规则库、冲突处理策略	WP.29 更偏“统一技术法规”，而美国这里明确要适配州法；对安全大脑而言核心是“法域可配置”。	把法规表达拆成：不可违反（硬约束）/优先级（软约束）/例外条款（条件触发）

(H) 网络安全方案：政策、风险识别评估缓解、预防纠正、事件响应、入侵检测等	CSMS 证据包（组织流程+威胁分析+生命周期）、车辆网络安全证据、事件响应演练	UN R155 明确要求 CSMS 与相关证明材料，是对齐最直接的法规锚点。	把“威胁场景→安全影响（对 DDT/MRC）→控制措施→验证证据”串成可追溯链
（关联项）软件更新（法案中在网络安全能力与系统更新机制里隐含，但在 WP.29 是显式门槛）	SUMS 证据包：版本管理、更新验证、回滚、适用性判断、更新后合规保持	UN R156 明确要求 SUMS 与软件更新合规证据，是欧盟/1958 体系的关键门槛。	把“更新前后安全主张是否仍成立”纳入 Safety Case 的变更管理（Delta Safety Case）

3.3 “证据包总目录”模板（可直接落地到规则工程）

把跨区域证据包拆成 6 个顶层包，基本能覆盖 SELF DRIVE + WP.29：

- 1. ODD & Scenario Library Pack（ODD 参数空间 + 场景本体 + 覆盖度）
- 2. System Architecture & Safety Mechanisms Pack（冗余、降级、MRC、接口与失效）
- 3. Safety Case Argument Pack（主张-论据-证据链；含验收准则）
- 4. Verification & Validation Pack（仿真/封闭场/道路；KPI 与统计口径）
- 5. CSMS Pack (UN R155)（威胁分析、组织流程、事件响应、监测）
- 6. SUMS Pack (UN R156)（版本/更新/回滚/验证/持续合规）

这 6 个包是一个监管接口结构，回答的问题是：监管机构需要看到什么，才能相信你的系统是安全的？

4 对中国自动驾驶监管的潜在影响

中国监管的底层特征是：强试点、强数据治理、强宣传与 OTA 约束、逐步放开 L3/L4。近期公开信息显示中国已经推进 L3 上路试点/许可，且对 OTA、宣传表述、L2/L3 安全要求的监管趋严。（[以上描述如果有误差请修正](#)）

在这种语境下，这部美国法案会带来几类影响：

4.1 “安全案例”可能成为中国自动驾驶规模化准入的关键制度工具

美国《2026 年自动驾驶安全法案》会带来结构性启示。中国目前的监管路径整体更偏向行政许可与试点驱动，主要表现为：

- 试点许可（地区试点、道路测试、示范运营）
- 事故上报与持续运营监管
- 车企宣传与功能命名约束
- OTA 更新审批或备案趋严

这种模式在“技术验证阶段”具有灵活性，但当自动驾驶从试点走向规模化、跨区域部署时，就会面临一个核心问题：如何在不同城市、不同省份之间形成统一的技术放行标准？这正是 Safety Case 机制的制度价值所在。

Safety Case 的结构意义：美国《2026 年自动驾驶安全法案》将 Safety Case 写入联邦法典，要求企业以“主张—论据—证据（Claim – Argument – Evidence）”结构证明系统不存在“不合理风险”，并覆盖：

- ODD 边界与能力说明
- DDT 执行机制
- 最小风险状态（MRC）
- VRU 识别与应对
- 应急车辆与特殊场景处理
- 网络安全与更新管理

其本质是把“系统安全证明”制度化，而不是单次审批化。

当中国自动驾驶产业从“地方试点 + 个案审批”走向：“全国规模化商业运营”时，单纯依赖地方许可与行政审批将难以支撑跨区域一致性。因此，一个可能的发展方向是，引入类似 Safety Case 的“证据包 / 论证包”机制，作为跨城市、跨省统一放行的技术底座。也就是说，不是简单扩大试点，而是建立可复制的安全论证结构，这与法案所确立的“主张—论据—证据”结构高度贴合。

在结构层面，现阶段中国更强调“行政许可 + 运营监管”，美国法案强调“风险论证 + 法律责任承载”。如果未来中国要实现 Robotaxi / 无驾驶员运营的规模化、跨区域常态化，那么 Safety Case 逻辑，作为统一技术放行的结构工具，将具有现实吸引力，可能借鉴其“风险论证结构”来解决规模化治理问题。

4.2. 中国可能不会照搬“联邦优先权”，但会更重视“全国口径统一”

美国用联邦优先权解决“州碎片化”；中国的挑战是各地试点规则差异；监管口径与责任边界不一致；企业跨城运营成本高。

本法案提供了一个非常清晰的启示：若要规模化，必须有“统一准入口径 + 可迁移合规材料”。中国更可能采取的不是“削地方权”，更可能是：

- 国家层面制定统一技术合规包模板
- 地方仍做运营与道路组织治理
- 形成“国家标准+地方许可”的两层结构

4.3 网络安全与软件更新：中欧趋同更强，美国法案提供“安全案例化”表达

法案通过建立国家 ADS 安全数据库，在联邦层面统一事故定义、上报标准与里程统计口径，使运行数据成为持续监管的核心工具。这种机制的重点不只是事故追责，而是用统一数据口径进行宏观风险监测与行业透明化管理，在制度上把“事故 + 运行里程”绑定为风险评估的基础单位，使监管能够基于暴露量（exposure）而非单一事件进行判断。

中国的既有趋势则更强调：

- 数据安全与数据出境约束
- 车端数据治理与合规流程
- 对 OTA 更新与缺陷整改的强监管
- 企业数据留存与监管可调取能力

近期围绕车辆数据出境、敏感地理信息处理、以及车企数据合规责任的公开讨论也在持续升温。因此，美国法案对中国的启发点可能在于：会进一步强化“国家级事故数据库 + 统一里程统计口径”这一运行数据治理模式。但是，中国的路径不会简单复制交通安全逻辑，而是会把这一机制更深地嵌入到国家数据治理与安全审查框架中。

美国强调的是“安全透明度与风险监测”；中国则更可能叠加“数据主权、跨境流动控制、网络安全审查”等维度。因此，中国未来的“国家数据库”如果形成，其功能边界可能不只是交通安全监管工具，而是：交通安全 + 数据安全 + 国家治理能力的一体化平台。

4.4. 对中国产业的“正负效应”预判

正面

1. 中国企业出海对标更清晰：若美国走 Safety Case 路线，中国企业会更早建立“证据包工程能力”，利于全球竞争（尤其与欧盟型式认证“材料工程”可形成互通）。
2. 推动国内监管从“试点”走向“可复制的准入机制”：有利于 Robotaxi/干线物流跨区域扩张。

负面/挑战

1. 合规成本上升：Safety Case 类机制对中小团队是门槛，可能加速行业分化。
2. 数据治理更复杂：如果安全监管也要求更细颗粒运行数据，而数据出境/存储又受限制，会给跨国研发、云训练、跨区域运营带来更高摩擦。
3. 宣传与责任边界更敏感：中国已对“智能/自动驾驶”等营销用语进行收紧，随着 L3 放开，责任叙事会更严格，车企需要更谨慎的 HMI/用户责任设计。

4.5 结论

如果把欧盟（WP.29）与美国（SELF DRIVE 2026）看成两种不同监管范式，中国很可能走“混合路线”：

型式 / 标准层更接近欧盟：在网络安全、软件更新、功能安全、信息安全等方面采取清单化、标准化、强制化路径，通过国家标准与强制性认证形成技术底座。

L4 运营准入层更接近美国：引入类似 Safety Case 的“安全论证包”机制，要求企业以“主张—论据—证据”结构证明系统不存在不可接受风险，并在此基础上建立跨城市、跨省统一的准入门槛。同时配套统一事故定义、统一里程统计口径与国家级运行数据库，实现规模化放行与持续风险监测的制度衔接。

这一逻辑与美国《2026 年自动驾驶安全法案》所体现的“风险论证 + 联邦统一口径”结构具有明显相似性。

数据治理层形成中国自己的强化版本：在交通安全监管之外，叠加更强的数据安全、数据出境审查、国家安全与地理信息安全要求。与欧美相比，这一层级的约束可能更深地嵌入国家整体数据治理体系，而不仅仅是行业监管。

“混合路线”既可维持行政可控性，又可为 L4/L5 的规模化运营预留制度空间，同时强化国家层面的数据治理能力。

5 法案与安全大脑的关系

5.1 法案的监管对象

SELF DRIVE Act 的核心不是“算法性能”，监管的是三件事：

1. 系统是否能持续执行 DDT
2. 是否能识别 ODD 边界
3. 是否能在风险出现时收敛到 MRC
4. 是否有可论证的 Safety Case 证据链

也就是说，监管的是“风险控制结构”，不是感知精度。所以这是一个“结构”监管法案。

5.2 “安全大脑”在这个结构里的位置

安全大脑的设计原则是“判断先于优化 (Judgment before Optimization)”。我们可以把自动驾驶系统拆成两层，左脑负责优化 (Optimization Brain: 轨迹规划、预测、控制、舒适性、效率)，右脑负责判断 (Safety Brain: 危险识别、运行边界判断、冗余与降级、风险提前收敛、MRC 触发、不可越界规则)，就会发现，SELF DRIVE 监管的几乎全部核心能力，都属于“安全大脑”的范畴。例如：

- 法案要求 → 对应安全大脑功能
- ODD 边界识别 → 运行域监测模块
- VRU 保护 → 弱势对象优先级规则
- 最小风险状态 → 收敛控制器
- L3 接管逻辑 → 风险升级管理
- 网络攻击防御 → 安全完整性保护
- 安全案例论证 → 风险结构建模

所以安全大脑与新法案不是“支持”的关系，而是法案在法律层面要求存在一个“安全大脑”。

5.3 Safety Case 与安全大脑的深层关系

Safety Case 本质上要求必须证明系统不会带来“不合理风险”。这个证明不可能仅靠统计里程、平均事故率、神经网络精度，而是必须依赖

- 危险模式枚举
- 风险分级
- 收敛策略
- 不变量证明
- 边界识别机制

而这都是安全大脑的建模对象。可以说，安全大脑是 Safety Case 这个“法律形式”的“工程实现”。

5.4 如果没有安全大脑，怎样开展 Safety Case 验证？

如果没有安全大脑，为了满足 Safety Case 要求，开发者会：

- 用大量测试覆盖替代结构安全
- 用概率指标替代风险收敛证明
- 用运营限制替代结构能力
- Safety Case 会逐渐变成文档游戏

法案允许提交“论证”，但法案并不替你设计结构。如果没有安全大脑架构，Safety Case 很难真正成立。

根据“判断先于优化”的原则，目前安全大脑已经涉及的领域包括：

- 规则化风险推理
- ODD 边界表达
- MRC 收敛机制
- 知识图谱式危险枚举
- 规则可插拔

这都意味着可以把“法律条款”翻译成“可执行结构”。所以安全大脑并不是抽象哲学，而是未来合规工程的核心。

SELF DRIVE Act 在制度上完成了把“责任承担主体”从驾驶员转移到制造商这一任务。而制造商承担责任的唯一方式是：能够证明系统在风险出现时不会失控。这就是安全大脑存在的理由。安全大脑不是为了优化，而是为了保证系统永远有一个“收敛结构”。

前面 3.1 和 3.2 的映射表在结构层面已经回答了“安全大脑与法案关联”的这个问题。如果作显式化表达，可以说安全大脑 = Safety Case 的工程载体，SELF DRIVE = 安全大脑合法化的制度基础。法律正在为“安全大脑型架构”创造必然需求。

5.5 法规条款的可落地“安全大脑系统架构”

以下把 § 30130(b)(4) 核心能力 直接翻译成一个工程系统结构。

依据 § 30130(b)(4) A – H 条款构建如夏《合规驱动型安全大脑架构蓝图》（Compliance-Driven Safety Brain Architecture Blueprint）

总体结构：安全大脑不是替代规划控制系统，而是独立于优化轨迹规划之外的“风险收敛与边界守卫系统”，完整的安全大脑结构可以分成 8 个核心模块（与 § 30130 核心能力一一对应）

模块 1：ODD 边界识别与运行域监测模块

（对应 § 30130(b)(4)(A)）

法规要求

- 在 ODD 内执行 DDT
- 能识别 ODD 边界

工程转译

- 实时判断是否仍处于设计运行域
- 识别条件退化（天气、定位、感知退化等）

子模块：

1. ODD 参数建模引擎（结构化表达）
2. 运行环境监测器
3. 置信度评估器

4. 边界预测器（提前触发退出）

核心输出：

- ODD_Valid = TRUE / FALSE
- ODD_Risk_Level $\in$ {Normal, Warning, Exit}

模块 2：弱势道路使用者风险优先模块

（对应 § 30130(b)(4)(B)）

法规要求：必须检测并妥善应对 VRU。

工程转译：这不是感知精度问题。这是风险优先级问题。

功能目标：

- 建立 VRU 风险加权体系
- 提前收敛风险轨迹

子模块：

1. VRU 类型识别映射
2. 风险暴露时间预测
3. 优先级重排序引擎
4. 保护动作约束器

原则：VRU 风险 > 车对车风险 > 财产风险

模块 3：L3 接管管理模块

（对应 § 30130(b)(4)(C)）

法规要求

- 状态明确传达

- 足够接管时间
- 接管前保持控制

工程转译：这是一个状态机问题。

子模块：

1. 系统状态广播器
2. 接管倒计时管理器
3. 驾驶员准备度评估器
4. 接管失败分支控制器

关键能力：接管失败自动进入 MRC

模块 4：最小风险收敛控制模块（MRC Engine）

（对应 § 30130(b)(4)(D)）。这是安全大脑的核心。

法规要求：L4/L5 必须能进入最小风险状态。

工程转译：

- 无论何种风险输入
- 系统必须存在一个收敛终态

子模块：

1. 风险触发判定器
2. 收敛路径生成器
3. 安全停车决策器
4. 外部警示协同器

MRC 是系统“不可突破的不变量”。

模块 5：ODD 违约降级策略模块

(对应 § 30130(b)(4)(E))

法规要求，当 ODD 条件不满足时：

- L4/L5 → MRC
- L3 → 请求接管

工程转译：这是一个降级决策树。

核心逻辑：

```
IF ODD_Valid = FALSE
  IF Level ≥ 4 → MRC
  ELSE → Request_Takeover
```

模块 6：特殊事件与法规情境响应模块

(对应 § 30130(b)(4)(F)(G))

法规要求识别：

- 应急车辆
- 校车
- 应急人员
- 并遵守交通法规

工程转译

- 法规规则库
- 情境识别逻辑
- 行为模板切换器

是一个规则插件系统。不同法域加载不同规则包。

模块 7：网络安全防护模块

(对应 § 30130(b)(4)(H))

法规要求必须：

- 有书面政策
- 风险识别
- 缓解流程
- 入侵检测

工程转译：安全大脑必须监测：

- 虚假控制指令
- 数据篡改
- 控制链路异常

子模块：

1. 控制完整性验证器
2. 异常指令检测器
3. 安全隔离机制
4. 网络攻击降级策略

网络攻击最终必须能触发 MRC。

模块 8：合规追溯与证据生成模块

(Safety Case Engine) 虽然不在 (b)(4)，但在 (b)(3)。这是安全大脑对外的接口。

功能：

- 自动记录风险触发日志
- 生成合规证据

- 输出结构化风险报告

本架构的关键原则

1. 安全大脑独立于规划
2. 风险必须可枚举
3. 所有异常必须收敛
4. 无边界不可运行
5. 不存在“未知状态”

SELF DRIVE 法案要求：

- ODD 识别
- VRU 保护
- 接管逻辑
- MRC 能力
- 网络安全
- 可证明安全

安全大脑架构需要将这些条款翻译成系统模块，否则法案条款无法工程化。

安全大脑不是某种单一技术，但为 safety case 提供结构性解决方案。

SELF DRIVE Act 在法律层面说要求“你必须证明系统不会带来不合理风险”，安全大脑则在工程层面回答“我如何保证系统始终收敛”。

6 安全大脑的机遇

安全大脑的“Judgement before Optimization”原则与 safety case 高度契合，所以本法案给安全大脑提供了立法基础。

由于 Safety Case 验证工作量较大，过程比较复杂，不一定所有的企业都能承担得起，业会给中小企业也会面临生存压力。

益普华安可以专注于 Safety Case 领域服务（咨询+工具包），一旦开始推行 Safety Case，安全大脑会处于独特的优势位置。

附录 — Safety Case 简介

1 Safety Case 的起源

Safety Case 不是汽车行业发明的，传统汽车行业对 Safety Case 也不熟悉。概念最早来自英国核工业（1970s–1980s）。在英国核监管体系中：

- 不采用“固定规则列表”
- 要求运营方提交 Safety Case
- 证明核设施在其运行条件下是安全的

这就是最早的制度化 Safety Case。

1988 年英国北海油田发生 Piper Alpha 事故之后，英国政府在海上石油与天然气行业引入了“Case-based regulation”，规定企业必须提交 Safety Case 才能运营。Safety Case 思想后来被吸收到：

- 航空适航认证
- ARP4761 安全评估流程
- DO-178C 软件认证体系

虽然航空更强调合规标准，但 Safety Case 结构化论证思维贯穿其中。后来，欧洲铁路、军工、航天等高风险系统也开始广泛使用 Safety Case。

2 Safety Case 的核心理念

Safety is not assumed. Safety must be argued and evidenced.

安全不是“达到某个数值指标”就自动成立。安全是一种结构化论证 (**structured argument**)。

Safety Case 的核心思想是：

1. 提出主张 (**Claim**)：系统在其运行域内是安全的。
2. 给出论据 (**Argument**)：为什么这个主张成立。
3. 提供证据 (**Evidence**)：测试、分析、数据、验证结果。
4. 控制假设 (**Assumptions**)：安全成立依赖哪些前提。
5. 管理不确定性 (**Uncertainty**)：风险是否被识别与收敛。

所以 Safety Case 不是“合规文件”，而是一种“可审查的安全证明结构”。

3 Safety Case 的构成要素

标准结构通常包括：

3.1 Top-Level Claim (顶层安全主张)

例如：The system is acceptably safe within its defined ODD。这是最核心的断言。

3.2 Sub-Claims (分解主张)

把总安全分解为：

- 系统功能安全
- 预期功能安全 (SOTIF)
- 网络安全
- 人机交互安全
- ODD 边界管理
- 最小风险收敛能力

3.3 Argument Structure (论证结构)

常用形式是：

- 归纳论证
- 演绎分解
- 场景覆盖论证
- 风险消减论证

通常用 **GSN (Goal Structuring Notation)** 表达。

3.4 Evidence (证据)

包括：

- 仿真数据
- 封闭场测试
- 公开道路数据
- 危险分析 (HARA / STPA)
- 统计证明
- 形式化验证

3.5 Assumptions & Context (假设与上下文)

例如：

- 运行仅限特定天气
- 仅在限定地理范围
- 用户遵守接管要求

Safety Case 必须显式声明这些内容。

3.6 Residual Risk Statement (剩余风险声明)

Safety Case 不要求“零风险”，而是要求：

- 风险被识别
- 风险被控制
- 剩余风险在可接受范围内

(这与安全大脑的主张完全一致)

4 Safety Case 进入自动驾驶

以往汽车业一直没跟随航空业采用 safety case，不是“不需要” Safety Case，而是没有“系统级不可预期风险”这种结构性压力。过去风险是机械性的，而不是行为生成性的。当风险从“零件失效”变成“决策失误”，Safety Case 就变成不可避免的结构工具。

核电、海上石油（Piper Alpha 之后）、航空、铁路等高风险行业的共同特征是：

- 单次事故 → 大规模死亡
- 系统高度耦合
- 运行环境复杂且不可完全测试
- 监管机构无法靠“列清单”保证安全

特征是很难再现特征和进行遍历检验，因此产生了一种监管逻辑：不再告诉企业“你必须满足这些条文”，而是要求企业证明“这个系统整体是安全的”。

传统汽车行业的风险结构与上面有所不同，主要特征是：

- 是“人主导机器”
- 事故主要归因于驾驶员
- 每辆车相对独立运行

- 故障是局部可分解的

因此监管模式是采用碰撞测试、刹车性能标准、零部件可靠性等标准，属于 Component compliance model（部件合规模型），只要满足法规清单，就可以销售，而不需要论证“整个驾驶行为系统是否安全”。

在传统汽车时代的语境下，上面这个逻辑是可行的，因为“决策者 = 驾驶员”，因此法律责任在人，制造商只需保证“产品无缺陷”，不需要证明“驾驶决策整体安全”。Safety Case 之所以出现，本质上是因为当“人不再是决策终点”时，就必须有人证明“系统级判断仍然存在”。

传统汽车功能确定，行为边界可枚举，场景空间有限，所以可以通过 FMEA、失效测试、极端工况等测试覆盖绝大多数风险。

Safety Case 是为了解决场景空间无法穷举、复杂交互不可完全测试、行为不是预编程而是动态生成等问题。在传统汽车里，这个问题并不严重。

一旦出现 L3+ 自动驾驶、OTA 软件更新、数据驱动决策、神经网络行为，ISO 26262 已经不够了，于是就出现了 SOTIF、UL 4600、欧盟 WP.29、美国 SELF DRIVE 法案 Safety Case 要求，本质都是要求企业证明“在不可完全测试的情况下，系统依然结构安全”。这就是 Safety Case 的汽车化。

汽车行业长期采用的是 Engineering sufficiency paradigm（工程充分性范式），过程是做够测试 → 满足标准 → 上市。而 Safety Case 属于 Argument-based assurance paradigm（论证型保障范式），要求保证

- 证明风险已被识别
- 证明控制逻辑闭环
- 证明剩余风险可接受

这对工程师文化是一次范式转换。英国（HSE）强调“你必须证明你安全”；美国传统汽车监管强调“你必须满足联邦机动车安全标准”。这两种制度逻辑差异非常大。自动驾驶让美国也开始转向 Safety Case。

5 Safety Case 与 ISO 26262 / SOTIF 三者之间的关系

5.1 差异

此前容易出现一个误解，以为 ISO 26262 + SOTIF 做完了，就等于完成了 Safety Case。实际上三者是不同层级的东西。但实际上，**ISO 26262 与 SOTIF 是“工程方法标准”**；**Safety Case 是“风险可接受性的整体论证框架”**。其间不是替代关系，但 26262 / SOTIF 是 Safety Case 的“证据来源之一”。

在概念上，Safety Case 是证明系统在其运行条件下不存在不可接受风险的“论证结构”，核心是：Claim（主张）、Argument（论证）和 Evidence（证据），回答的问题是“为什么可以相信这个系统是安全的”？，所以是一个合规与责任承载结构。

ISO 26262 是车辆电气/电子系统功能安全标准，核心关注：

- 硬件/软件随机失效
- ASIL 分级
- HARA
- 安全目标
- 技术安全要求
- V&V 流程

它回答的问题是：“如何防止由于系统失效导致的危险”？解决的是“失效驱动的风险”。

SOTIF（ISO 21448）解决的是“系统没有失效，但能力不足或感知不充分导致的危险”。例如：


- 误识别
- 边界场景
- 感知局限
- 长尾场景

它回答的问题是：“即使系统没有坏，是否仍然可能不安全？”

5.2 三者分工

风险来源	归属
硬件/软件失效	ISO 26262
性能不足/感知局限	SOTIF
运行条件/ODD 边界/系统能力整体合理性	Safety Case
法规合规/运营边界	Safety Case
数据/网络安全	Safety Case + R155

26262 和 SOTIF 解决“系统内部风险”；Safety Case 解决“系统整体是否可以进入公共道路”。



ISO 26262 和 SOTIF 是 Safety Case 里的“证据节点”。

从更宏观的角度理解，ISO 26262 解决“系统不会因为坏掉而出事”，SOTIF 解决“系统即使没坏，也不会因为能力不足而出事”，Safety Case 解决“整个系统在现实世界中部署是合理的”。

5.3 为什么 26262 ≠ Safety Case?

很多工程团队会说：我们已经做完 HARA、ASIL、FMEA、验证测试，安全了。但 Safety Case 关注的是：

- ODD 是否定义合理?
- 退出策略是否充分?
- MRC 是否可验证?
- VRU 是否覆盖?
- 数据是否持续监测?
- 更新后是否仍然安全?
- 运营规模扩大后风险是否仍可接受?

这些都不在 26262 的覆盖范围内。

SOTIF 与 Safety Case 的关键差别在于，SOTIF：

- 是一个技术标准
- 定义如何发现未知风险
- 定义触发场景与能力不足问题

Safety Case：

- 不规定“怎么做”
- 只问：你是否能证明它安全?

SOTIF 是方法论；Safety Case 是责任论证结构。

在 L4/L5 场景下的现实情况，对于 Robotaxi / 无驾驶员运营，如果只依赖 26262 + SOTIF，会出现三个缺口：

1. ODD 边界如何证明合理？
2. MRC 是否真正可执行？
3. 规模化运营后风险是否仍然可控？

这些只能通过 Safety Case 来整合论证。

6 在自动驾驶领域推行 Safety Case 的挑战与风险

Safety Case 在传统工程体系里非常强大，但进入 AI 时代（尤其是数据驱动、学习型系统）后，有可能暴露出结构性张力，也就是其“论证结构”与 AI 系统的“生成结构”之间存在内在冲突。

6.1 Safety Case 的原始假设

Safety Case 依赖三个隐含前提：

1. 系统结构是可描述的
2. 风险因果链是可解释的
3. 证据是稳定且可重复的

它本质上是一个“静态系统 + 可追溯因果 + 文档化证据”模型。这在航空、核电、传统控制系统中是成立的。

6.2 AI 时代的结构变化

AI 系统（尤其是深度学习）带来三种结构性变化：

1. 决策机制不再完全可解释

2. 风险来源转向“分布问题”而非“失效问题”
3. 系统能力随数据和更新动态变化

这三点直接冲击 Safety Case 的结构基础。

6.3 挑战一：不可解释性

Safety Case 需要：Claim → Argument → Evidence → 可审查逻辑链

但在 AI 系统中，

- 神经网络内部状态不可完全解释
- 决策边界不是规则形式
- 风险无法用确定性因果链表达

这导致一个问题：Argument 层变得抽象甚至形式化，而非真实可解释。通常可以证明：

- 测试覆盖率
- 数据分布
- 性能指标

但很难证明：

- 为什么模型在某场景下不会做出错误决策。

Safety Case 开始依赖统计置信，而不是因果证明。

（说明：安全大脑的规则引擎可以提供透明的推理链证明）

6.4 挑战二：风险不再是“失效”而是“分布偏移”

ISO 26262 的世界是 Failure → Hazard → Risk，但 AI 世界是：Distribution Shift → Unknown Behavior → Risk。Safety Case 本身仍偏向“已知风险可论证”，但 AI 的问题是：

- 未知场景
- 长尾分布
- 数据外推

这意味着证据永远是不完备的，Safety Case 会被迫变成：

- 大量仿真
- 大量统计测试
- 大量场景库

但仍然无法证明“覆盖未知未知”。

6.5 挑战三：动态系统 vs 静态论证

Safety Case 是“冻结时刻的论证”。AI 系统是

- OTA 更新
- 模型迭代
- 数据再训练
- 参数持续变化

这就产生一个结构冲突：论证结构是静态的，而系统能力是动态的。如果每次更新都要重写完整 Safety Case，那么会导致

- 成本巨大
- 审查滞后
- 创新受阻

如果不重写那么又会

- 证据失效
- 责任模糊

这就是所谓的“**Delta Safety Case** 困境”。

6.6 挑战四：规模化暴露问题

Safety Case 本质上证明的是单一系统在其 ODD 内可接受。但 AI 系统部署后：

- 上百万辆车
- 数十亿公里
- 行为产生网络效应

风险就由单车风险变成了系统性风险。Safety Case 没有内置“宏观风险监测结构”。这也是为什么 2026 法案里叠加了国家级数据库。

6.7 挑战五：责任与判断的外移

AI 系统在某些场景下进行价值权衡。例如：

- VRU 冲突
- 不可避免事故
- 决策取舍

Safety Case 只能证明风险被控制在合理范围内，但无法回答谁承担最终价值判断？在 AI 时代，判断被部分委托给模型。Safety Case 没有“价值治理模块”。

关于 AI 的责任与边界的讨论，可参考 Judgment before Optimization 一文
(<https://github.com/ShaoBoQiu/judgment-before-intelligence/blob/main/part-1-judgment-before-intelligence.md>)。

6.8 总结

Safety Case 的强项：

- 工程可追溯
- 法律责任清晰
- 可审查
- 可文档化

但在 AI 时代，它面临五个结构挑战：

1. 不可解释性
2. 分布外风险
3. 动态更新
4. 规模化系统性风险
5. 价值判断外移

在这个背景下，传统 Safety Case 并不会失效，只是需要升级为：

- 动态 Safety Case
- 数据驱动 Safety Case
- 分布意识型 Safety Case
- 运行中持续验证结构

这意味着，AI 时代的 Safety Case 不再是静态合规文件，而是运行中的安全论证系统。

目前安全大脑的

- ODD 本体
- MRC 规则化
- 风险预测
- 结构化证据链

本质上就是在尝试把 Safety Case 从文档转为可机读结构，这恰好是在 AI 时代必须走的方向。

接下来，还会逐渐会面临一个更深层次问题：当模型本身具备自学习能力时，Safety Case 是否还能作为“最终判断载体”？这个问题会直接触及“判断不可外包”的核心（详见 What Awakens in the Age of AI 一文，<https://github.com/ShaoBoQiu/judgment-before-intelligence/blob/main/What%20Awakens%20in%20the%20Age%20of%20AI.pdf>）。